

1 Metodologia

O objetivo deste experimento foi avaliar o impacto de diferentes técnicas de prompting na acurácia do modelo de linguagem Gemini para a correção de redações no formato ENEM. Foram utilizados os três prompts base a seguir: (1) prompt simples (baseline), (2) prompt com técnica Few-Shot e (3) prompt com técnica Chain-of-Thought (CoT). Para cada um deles, as 100 primeiras redações do dataset *essay-br*, distribuídas em 42 temas diferentes, foram avaliadas pelo modelo.

Todo o processo experimental foi implementado em Python, com o código aberto disponível no repositório público:

<https://github.com/gabriel-py/essay-br>

As análises ocorreram em três etapas sequenciais:

1.1 Etapa 1 — Envio das redações ao modelo Gemini

O script `analizador.py` recebe como entrada:

- O arquivo de dataset: `essay-br.csv`
- Um arquivo contendo o prompt base a ser utilizado
- O número de redações a serem analisadas ($N = 100$)

Antes da execução, é necessário configurar a variável de ambiente contendo o token de acesso ao Gemini:

```
export GEMINI_API_KEY="sua_api_key"
```

O envio é realizado com o seguinte comando:

```
python analisador.py --in essay-br.csv --prompt-file promptX.txt --n 100
```

onde `promptX.txt` é substituído por:

- `prompt1.txt` : baseline
- `prompt2.txt` : Few-shot
- `prompt3.txt` : Chain-of-Thought

Essa etapa gera um arquivo no formato:

`essay-br-100-with-ia_{prompt_base}.csv`

contendo os dados originais do dataset acrescidos de uma nova coluna com o resultado bruto retornado pelo modelo (`resultado_ia`).

1.2 Etapa 2 — Normalização das notas previstas

O script `gemini_normalizer.py` recebe como entrada o arquivo gerado na etapa anterior e extrai:

- Notas previstas por competência (C1–C5)
- Nota prevista total
- Notas reais separadas por competência

O comando utilizado é o seguinte e é necessário definir o nome do arquivo de entrada e saída, que estão hard code dentro do script:

```
python gemini_normalizer.py
```

O resultado é um arquivo no formato:

```
essay-br-100-with-ia-{prompt_base}_predicted_with_real.csv
```

organizado para facilitar o cálculo das métricas.

1.3 Etapa 3 — Cálculo das métricas por tema de redação

O script `metrics.py` agrupa os resultados por tema e calcula as métricas estatísticas de acurácia. O comando executado é o seguinte e é necessário definir o nome do arquivo de entrada e saída, que estão hard code dentro do script:

```
python metrics.py
```

o que gera o arquivo final:

```
essay-br-100-with-ia-{prompt_base}_predicted_with_real_metrics.csv
```

As métricas analisadas foram:

- **MAE** — Mean Absolute Error: mede o erro absoluto médio entre nota real e prevista (quanto menor, melhor)
- **QWK** — Quadratic Weighted Kappa: mede a concordância com avaliadores humanos (quanto mais próximo de 1, melhor)

Essa pipeline foi repetida uma vez para cada prompt base.

2 Resultados

Os resultados obtidos mostram que a qualidade do prompt influencia diretamente o desempenho do modelo Gemini na correção das redações ENEM. A Tabela 1 apresenta os valores consolidados das métricas para cada um dos três métodos testados.

Observa-se que:

- O prompt simples apresenta o maior erro e menor concordância com humanos
- A técnica Few-Shot melhora substancialmente o desempenho
- O método CoT atinge os melhores valores de MAE e QWK, aproximando-se do comportamento de avaliadores humanos

Esses resultados evidenciam que:

- A engenharia de prompts é crucial para o uso de LLMs em correção automática
- Quanto maior o nível de orientação fornecida à IA, mais consistentes se tornam suas avaliações

3 Conclusão

Este trabalho confirmou que a variação da técnica de prompting exerce influência direta e significativa na acurácia do modelo Gemini ao corrigir redações no formato ENEM. Entre os três métodos avaliados, o prompt com técnica Chain-of-Thought apresentou o melhor desempenho, alcançando o menor MAE (32,8) e a maior concordância humana medida por QWK (0,9415). Isso indica que o estímulo a um raciocínio estruturado aproxima o modelo de uma avaliação criteriosa e alinhada aos parâmetros oficiais.

Em segunda posição, o modelo utilizando Few-Shot obteve ganhos substanciais em relação ao baseline, demonstrando que fornecer exemplos concretos de como corrigir a redação ajuda a orientar o sistema sobre o formato e rigor esperados pelos avaliadores.

O prompt simples, por outro lado, apresentou os resultados mais fracos, evidenciando que um nível de orientação insuficiente leva a erros maiores e instabilidade temática.

Como trabalhos futuros, pretende-se investigar a aplicação de **prompts híbridos**, combinando as vantagens do Few-Shot com o poder de raciocínio promovido pelo Chain-of-Thought. A expectativa é que essa abordagem produza resultados ainda mais assertivos, embora represente um aumento de custo devido ao maior número de tokens processados por requisição ao modelo. Além disso, há interesse em expandir os experimentos para a totalidade do dataset e analisar o desempenho por competência individual da redação.

Os resultados obtidos reforçam que a engenharia de prompts desempenha papel essencial no uso confiável de modelos de linguagem em aplicações educacionais sensíveis, como a avaliação automatizada de redações no ENEM.

Table 1: Métricas agregadas por tipo de prompt

Prompt	Técnica	MAE Total ↓	QWK Total ↑
Prompt 1	Simples	52,8	0,8760
Prompt 2	Few-Shot	36,8	0,9005
Prompt 3	Chain-of-Thought	32,8	0,9415